

数值分析

数值积分和数值微分

参考书目:

- Numerical Analysis (David Kincaid, Ward Cheney)
- Numerical Analysis (Timothy Sauer, 2014)
- Approximation Theory and Approximation Practice (Trefethen, 2013)

1 数值微分

最常见的数值微分是直接差分法。如果记 D_+ 为前向差分算子, 后向差分算子为 D_- , 中心差分算子为 D_0 , 即

$$D_+u(t) = \frac{u(t+h) - u(t)}{h}, \quad D_-u(t) = \frac{u(t) - u(t-h)}{h}, \quad D_0u(t) = \frac{u(t+h) - u(t-h)}{2h},$$

则它们都可以用来近似 $u'(t)$, 使用带余项的 Taylor 展开可以看到

$$D_+u(t) = u'(t) + \frac{h}{2}u''(\xi_+), \quad D_-u(t) = u'(t) + \frac{h}{2}u''(\xi_-), \quad D_0u(t) = u'(t) + \frac{h^2}{6}u'''(\xi_0),$$

所以前两种单侧差分是一阶的, 中心差分是二阶的。为了近似更高阶的导数, 我们可以使用更高阶的差分算子, 例如

$$D_+D_-u(t) = \frac{u(t+h) - 2u(t) + u(t-h)}{h^2} = u''(t) + \frac{h^2}{12}u^{(4)}(\xi)$$

是二阶中心差分, 具有二阶精度; 类似地, 使用待定系数法, 考虑

$$\sum_{k=-l}^r a_k u(t+kh) = u^{(n)}(t) + O(h^n),$$

将左侧使用 Taylor 展开, 令两侧各阶系数相等可以求出 a_k 的值。另外, 给出两个常用的单侧差分算子:

$$\frac{3u(t) - 4u(t+h) + u(t+2h)}{-2h} = u'(t) + O(h^2), \quad \frac{u(t-2h) - 4u(t-h) + 3u(t)}{2h} = u'(t) + O(h^2).$$

1.1 插值型微分

借助多项式插值, 我们可以得到一大类数值微分方法, 这类方法称为插值型微分, 其基本思想是先使用多项式对原函数进行插值, 之后使用该插值多项式的导数来近似原函数的导数。当使用 Lagrange 插值时, 回忆其满足

$$f(x) = \sum_{i=0}^n f(x_i)\ell_i(x) + \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \prod_{i=0}^n (x-x_i), \quad (1.1)$$

其中 $\ell_i(x)$ 是 Lagrange 插值基函数 $\prod_{j \neq i} (x-x_j)/(x_i-x_j)$ 。对上式的两侧求导可得

$$f'(x) = \sum_{i=0}^n f(x_i)\ell'_i(x) + \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \frac{d}{dx} \prod_{i=0}^n (x-x_i) + \frac{1}{(n+1)!} \prod_{i=0}^n (x-x_i) \frac{d}{dx} f^{(n+1)}(\xi_x). \quad (1.2)$$

考虑该近似在某插值节点 x_k 上的值, 则

$$f'(x_k) = \sum_{i=0}^n f(x_i)\ell'_i(x_k) + \frac{f^{(n+1)}(\xi_{x_k})}{(n+1)!} \frac{d}{dx} \prod_{i=0}^n (x-x_i)|_{x=x_k}, \quad (1.3)$$

因为

$$\frac{d}{dx} \prod_{i=0}^n (x_k - x_i) = \sum_{i=0}^n \prod_{j \neq i}^n (x_k - x_j) = \prod_{j \neq k} (x_k - x_j),$$

所以插值型微分的误差为

$$f'(x_k) - \sum_{i=0}^n f(x_i) \ell'_i(x_k) = \frac{f^{(n+1)}(\xi_{x_k})}{(n+1)!} \prod_{j \neq k} (x_k - x_j). \quad (1.4)$$

1.2 Richardson 外推法

注意到数值微分的误差往往形如

$$Ch^n + O(h^{n+1}),$$

其中 C 是与 h 无关的常数, 因此我们可以使用外推法来提高精度, 具体来说, 我们可以使用两个不同的步长 h_1 和 h_2 , 得到两个近似值 u_1 和 u_2 , 将他们进行线性组合以消去误差中的主要部分从而提高数值精度。一般地, 对于一个相容的数值微分方法我们有

$$Lu = \varphi(h) + a_1 h + a_2 h^2 + a_3 h^3 + a_4 h^4 + \cdots, \quad (1.5)$$

其中 L 是差分算子, $\varphi(h)$ 是使用 u 在某些节点处的值组合得到的数值微分, h 是步长, 剩余的部分是误差项。为了消除一阶误差项, 分别使用 h 和 $h/2$ 的步长得到两个近似值 u_1 和 u_2 , 则

$$\begin{aligned} Lu &= \varphi(h) + a_1 h + a_2 h^2 + a_3 h^3 + a_4 h^4 + \cdots, \\ &= \varphi(h/2) + a_1 h/2 + a_2 h^2/4 + a_3 h^3/8 + a_4 h^4/16 + \cdots, \end{aligned}$$

将第二行乘二并减去第一行, 可以得到

$$Lu = 2\varphi(h/2) - \varphi(h) - \frac{a_2}{2} h^2 - \frac{3a_3}{4} h^3 + \cdots,$$

因此 $2\varphi(h/2) - \varphi(h)$ 是一个具有二阶截断误差的更高精度的数值微分。

以上方法称为 Richardson 外推法, 重复使用它可以提高数值微分的精度。 M 步的 Richardson 外推法在每步分为两个阶段:

1. 选取合适的步长 h 并计算前 $M+1$ 个数值近似值, 并记为

$$D(n, 0) = \varphi(h/2^n), \quad n = 0, 1, \cdots, M. \quad (1.6)$$

2. 逐项消去高阶误差项, 使用以下递推公式计算 $D(n, k)$:

$$D(n, k) = \frac{2^k}{2^k - 1} D(n, k-1) - \frac{1}{2^k - 1} D(n-1, k-1), \quad (1.7)$$

其中 $n = k, \cdots, M, k = 1, 2, \cdots, n$ 。

使用数学归纳法可知按照以上方法得到的 $D(n, k)$ 具有 $k+1$ 阶截断误差。

当使用中心差分法时, 误差中不含有奇数次的项, 因此我们可以将第二个阶段中的递推关系改为

$$D(n, k) = \frac{4^k}{4^k - 1} D(n, k-1) - \frac{1}{4^k - 1} D(n-1, k-1), \quad (1.8)$$

此时 $D(n, k)$ 的截断误差阶数为 $2(k+1)$ 。

通常 Richardson 外推法的计算借助于以下的表格:

| | | | | |
|-----------|-----------|-----------|----------|-----------|
| $D(0, 0)$ | | | | |
| $D(1, 0)$ | $D(1, 1)$ | | | |
| $D(2, 0)$ | $D(2, 1)$ | $D(2, 2)$ | | |
| \vdots | \vdots | \vdots | \ddots | |
| $D(M, 0)$ | $D(M, 1)$ | $D(M, 2)$ | \cdots | $D(M, M)$ |

每次计算 $D(n, k)$ 时需要使用 $D(n, k-1)$ 和 $D(n-1, k-1)$, 因此可以从左上角开始逐列计算。

2 数值积分

数值积分可以视作数值微分的逆运算，其目的是计算定积分

$$I = \int_a^b f(x)dx.$$

最简单的积分方法包括矩形法、梯形法和 Simpson 法则，这些方法都是插值型积分方法的特例。所谓插值型积分方法是指先对被积函数进行多项式插值，之后对插值多项式进行积分。当使用 Lagrange 插值时，我们有

$$f(x) = \sum_{i=0}^n f(x_i) \ell_i(x) + \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \prod_{i=0}^n (x - x_i),$$

两侧同时积分可得

$$\int_a^b f(x)dx = \sum_{i=0}^n f(x_i) \int_a^b \ell_i(x)dx + \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \int_a^b \prod_{i=0}^n (x - x_i)dx,$$

记其中与 f 无关的

$$\int_a^b \ell_i(x)dx := A_i, \quad (2.1)$$

则 f 的插值型数值积分可以表示为

$$\sum_{i=0}^n A_i f(x_i), \quad (2.2)$$

相应的数值误差为

$$\int_a^b \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \prod_{i=0}^n (x - x_i)dx, \quad (2.3)$$

使用绝对值不等式可得

$$\left| \int_a^b \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \prod_{i=0}^n (x - x_i)dx \right| \leq \frac{M}{(n+1)!} \int_a^b \prod_{i=0}^n |x - x_i|dx, \quad (2.4)$$

其中 $M = \max_{x \in [a,b]} f^{(n+1)}(x)$ 。

与连续空间上的最佳逼近类似，我们希望最小化上述误差，为此需要寻找合适的插值节点 x_i ，这一问题可以转化为如下最优化问题：

$$\min_{x_0, \dots, x_n} \int_a^b \prod_{i=0}^n |x - x_i|dx, \quad (2.5)$$

可以证明在 $[a, b] = [-1, 1]$ 时，当且仅当 x_0, \dots, x_n 是第二类 Chebyshev 点，即第二类 Chebyshev 多项式 $U_{n+1}(x) = \sin[(n+2) \arccos x] / \sin(\arccos x)$ 的零点时上式取到最小值 2^{-n} ，即

$$\int_{-1}^1 \prod_{i=0}^n |x - x_i|dx = 2^{-n}, \quad (2.6)$$

相应的插值点，即第二类 Chebyshev 点为

$$x_i = \cos\left(\frac{i+1}{n+2}\pi\right), \quad i = 0, 1, \dots, n. \quad (2.7)$$

于是我们有如下误差估计：

$$\left| \int_{-1}^1 f(x)dx - \sum_{i=0}^n A_i f(x_i) \right| \leq \frac{M}{2^n(n+1)!}. \quad (2.8)$$

当区间为一般的 $[a, b]$ 时，使用坐标变换

$$x = \frac{b-a}{2}t + \frac{a+b}{2}$$

可以将区间变换到 $[-1, 1]$ 上，此时插值型积分的误差为

$$\left| \int_a^b f(x)dx - \sum_{i=0}^n A_i f(x_i) \right| \leq \frac{M}{(n+1)!} \int_{-1}^1 \prod_{i=0}^n \frac{b-a}{2} |t - t_i| \cdot \frac{b-a}{2} dt \leq \frac{M}{2^n(n+1)!} \cdot \left(\frac{b-a}{2}\right)^{n+2}. \quad (2.9)$$

2.1 Newton-Cotes 公式

如果不追求特别高的精度,等距节点的插值点是最简单的选择,相应的插值型积分方法称为 Newton-Cotes 插值。最简单的 Newton-Cotes 公式是矩形法、梯形法和 Simpson 法则,它们分别对应于 $n = 0, 1, 2$ 的情形。对于 $n = 0$ 的情形,我们有

$$\int_a^b f(x)dx \approx f(a)(b-a) \text{ or } f(b)(b-a), \quad (2.10)$$

也可以使用中点法,即

$$\int_a^b f(x)dx \approx f\left(\frac{a+b}{2}\right)(b-a). \quad (2.11)$$

这种情况下我们只使用一个插值点 $x_0 = a, b$ 或者 $(a+b)/2$ 。根据插值型积分的误差估计可知 $x_0 = a, b$ 时方法的误差为

$$f'(\xi) \int_a^b (x-x_0)dx = \pm \frac{f'(\xi)}{2}(b-a)^2,$$

不过当使用中点法时,由于正负误差恰好相互抵消,误差阶数上升为 $O((b-a)^3)$ 。

对于 $n = 1$ 的情形,我们有

$$\int_a^b f(x)dx = \frac{f(a)+f(b)}{2}(b-a) + O((b-a)^3), \quad (2.12)$$

注意到当 $x_0 = a, x_1 = b$ 时, Lagrange 插值基函数为

$$\ell_0(x) = \frac{x-b}{a-b}, \quad \ell_1(x) = \frac{x-a}{b-a},$$

计算 A_0, A_1 可得

$$A_0 = \int_a^b \ell_0(x)dx = \frac{b-a}{2}, \quad A_1 = \int_a^b \ell_1(x)dx = \frac{b-a}{2},$$

所以我们有

$$\int_a^b f(x)dx \approx A_0 f(x_0) + A_1 f(x_1) = \frac{f(a)+f(b)}{2}(b-a),$$

由此可见梯形法则是 $n = 1$ 的 Newton-Cotes 公式。根据之前的分析可知

$$\int_a^b f(x)dx - \frac{f(a)+f(b)}{2}(b-a) = \int_a^b \frac{f''(\xi_x)}{2}(x-a)(x-b)dx = \frac{f''(\xi)}{2} \int_a^b (x-a)(x-b)dx,$$

其中使用到了积分中值定理,于是该方法的误差为

$$\int_a^b f(x)dx - \frac{f(a)+f(b)}{2}(b-a) = -\frac{1}{12}f''(\xi)(b-a)^3.$$

对于 $n = 2$ 的情形, Lagrange 基函数变为

$$\ell_0(x) = \frac{(x-x_1)(x-x_2)}{(x_0-x_1)(x_0-x_2)}, \quad \ell_1(x) = \frac{(x-x_0)(x-x_2)}{(x_1-x_0)(x_1-x_2)}, \quad \ell_2(x) = \frac{(x-x_0)(x-x_1)}{(x_2-x_0)(x_2-x_1)},$$

计算 A_0, A_1, A_2 可得

$$A_0 = \int_a^b \ell_0(x)dx = \frac{b-a}{6}, \quad A_1 = \int_a^b \ell_1(x)dx = \frac{2(b-a)}{3}, \quad A_2 = \int_a^b \ell_2(x)dx = \frac{b-a}{6},$$

由此可知 $n = 2$ 的 Newton-Cotes 公式为

$$\int_a^b f(x)dx \approx A_0 f(x_0) + A_1 f(x_1) + A_2 f(x_2) = \frac{b-a}{6} \left[f(a) + 4f\left(\frac{a+b}{2}\right) + f(b) \right], \quad (2.13)$$

此即 Simpson 法则。与之前类似地借助积分中值定理可知该方法的误差为

$$\int_a^b f(x)dx - \frac{b-a}{6} \left[f(a) + 4f\left(\frac{a+b}{2}\right) + f(b) \right] = -\frac{1}{90}f^{(4)}(\xi)\left(\frac{b-a}{2}\right)^5.$$

通常为了提高精度,我们可以将区间 $[a, b]$ 等分为 n 个子区间,然后在每个子区间上使用 Newton-Cotes 公式,这种方法称为复合 Newton-Cotes 公式。当使用等距划分 $a = x_0 < x_1 < \cdots < x_{n-1} < x_n = b$ 时,复合梯形法则为

$$\int_a^b f(x)dx = \sum_{i=1}^n \int_{x_{i-1}}^{x_i} f(x)dx \approx \frac{h}{2} \left[f(x_0) + 2 \sum_{i=1}^{n-1} f(x_i) + f(x_n) \right], \quad (2.14)$$

其中 $h = (b - a)/n$, 数值误差为

$$-\frac{1}{12}(b-a)h^2 f''(\xi).$$

复合 Simpson 法则为

$$\int_a^b f(x)dx = \sum_{i=1}^n \int_{x_{i-1}}^{x_i} f(x)dx \approx \frac{h}{3} \left[f(x_0) + 4 \sum_{i=1}^{n/2} f(x_{2i-1}) + 2 \sum_{i=2}^{n/2} f(x_{2i-2}) + f(x_n) \right], \quad (2.15)$$

数值误差为

$$-\frac{1}{180}(b-a)h^4 f^{(4)}(\xi).$$

一般的 Newton-Cotes 公式可以借助待定系数法来构造, 由于插值节点已经确定, 我们只需要计算 A_i 的值。通常我们需要选取 A_i 以使得相应的 Newton-Cotes 公式具有尽可能高的精度, 一般 $n+1$ 个节点的 Newton-Cotes 公式最高可以达到 n 阶代数精度, 即对于任意阶数不超过 n 的多项式 $p(x)$, 有

$$\int_a^b p(x)dx = \sum_{i=0}^n A_i p(x_i),$$

即数值积分是准确的。要求 $n+1$ 个节点的 Newton-Cotes 公式具有 n 阶代数精度可以确定 A_i 的值。要令 $n+1$ 个节点的 Newton-Cotes 公式具有 n 阶代数精度, 只需

$$\int_a^b x^k dx = \sum_{i=0}^n A_i x_i^k, \quad k = 0, 1, \dots, n, \quad (2.16)$$

写成矩阵形式即

$$\begin{pmatrix} 1 & 1 & \cdots & 1 \\ x_0 & x_1 & \cdots & x_n \\ \vdots & \vdots & \ddots & \vdots \\ x_0^n & x_1^n & \cdots & x_n^n \end{pmatrix} \begin{pmatrix} A_0 \\ A_1 \\ \vdots \\ A_n \end{pmatrix} = \begin{pmatrix} b-a \\ \frac{b^2-a^2}{2} \\ \vdots \\ \frac{b^{n+1}-a^{n+1}}{n+1} \end{pmatrix},$$

注意到系数矩阵是 Vandermonde 矩阵且使用的是等距节点, 因此该线性方程组是非奇异的, 方程有界, 解该线性方程组即可得到 A_i 的值。然而该方法的缺点是当 n 较大时, Vandermonde 矩阵的条件数会变得很大, 因此数值稳定性会变得很差。另一种方法是不再考虑 x^k , 而是换用 $(x-x_0)\cdots(x-x_k)$, 这种情况下有

$$\int_a^b \prod_{j=0}^k (x-x_j) dx = \sum_{i=k+1}^n A_i \prod_{j=0}^k (x_i-x_j), \quad (2.17)$$

于是矩阵形式变为

$$\begin{pmatrix} 1 & 1 & 1 & \cdots & 1 \\ (x_1-x_0) & (x_2-x_0) & \cdots & (x_n-x_0) \\ & (x_2-x_0)(x_2-x_1) & \cdots & (x_n-x_0)(x_n-x_1) \\ & & \ddots & \vdots \\ & & & \prod_{j=0}^n (x_n-x_j) \end{pmatrix} \begin{pmatrix} A_0 \\ A_1 \\ \vdots \\ A_n \end{pmatrix} = \begin{pmatrix} b-a \\ \int_a^b (x-x_0)dx \\ \vdots \\ \int_a^b \prod_{j=0}^n (x-x_j)dx \end{pmatrix},$$

这样系数矩阵变为上三角矩阵, 因此可以使用回代法求解。

更一般地, 我们有广义 Newton-Cotes 公式, 这类方法使用等距节点插值计算加权积分

$$\int_a^b f(x)w(x)dx \approx \sum_{i=0}^n A_i f(x_i), \quad (2.18)$$

其中 $w(x) > 0$ 是权函数, A_i 是待定系数。

2.2 Gauss 积分公式

通过仔细选取插值节点, 我们可以将插值型积分的精度提高到 $2n+1$ 阶, 相应的积分方法称为 Gauss 积分。考虑一般的广义插值问题:

$$\int_a^b f(x)w(x)dx = \sum_{i=0}^n A_i f(x_i), \quad (2.19)$$

Gauss 积分使用插值节点 x_0, \dots, x_n 是关于 w 的 $n+1$ 阶广义正交多项式的零点。广义正交多项式的定义如下。

Definition. 如果 $n+1$ 阶多项式 Q 满足

$$\int_a^b P(x)Q(x)w(x)dx = 0, \quad \forall P \in \mathcal{P}_n, \quad (2.20)$$

则称 Q 是关于 w 的 $n+1$ 阶广义正交多项式。

注意到对任意 $f \in \mathcal{P}_{2n+1}$ 都可以使用带余除法写为

$$f(x) = Q(x)g(x) + r(x), \quad \deg r < \deg Q = n+1,$$

进而 $f(x_i) = r(x_i)$ 。又因为 f 至多 $2n+1$ 阶, 所以 $\deg g \leq n$, 因此使用 Q 的 w 正交性有

$$\int_a^b f(x)w(x)dx = \int_a^b Q(x)g(x)w(x)dx + \int_a^b r(x)w(x)dx = \sum_{i=0}^n A_i r(x_i) = \sum_{i=0}^n A_i f(x_i), \quad (2.21)$$

因此该积分公式具有 $2n+1$ 阶代数精度。

在使用 Gauss 积分时首先需要确定相应的广义正交多项式, 通常可以使用 Gram-Schmidt 正交化方法来构造, 其中使用关于 w 的广义内积:

$$\langle f, g \rangle = \int_a^b f(x)g(x)w(x)dx. \quad (2.22)$$

可以验证广义正交多项式的所有根都是 (a, b) 内实的单根。

最后我们对 Gauss 积分的误差进行估计。我们先给出 Gauss 积分的一些性质。

Lemma 1. Gauss 积分公式中的系数 A_i 都是正的, 且满足

$$\sum_{i=0}^n A_i = \int_a^b w(x)dx. \quad (2.23)$$

Proof. 先说明 $A_i > 0$ 。令 Q 是关于 w 的 $n+1$ 阶广义正交多项式, 设它的根为 x_0, \dots, x_n , 令 $P(x) = Q(x)/(x - x_i)$, 其中 x_i 是 Q 的某一根, 因此 P 是 n 阶多项式, 因为 Gauss 积分具有 $2n+1$ 阶代数精度, 所以对 P^2 使用 Gauss 积分有

$$0 = \int_a^b P^2(x)w(x)dx = \sum_{j=0}^n A_j P^2(x_j) = A_i P^2(x_i),$$

所以 $A_i > 0$ 。另外, 对 $Q = 1$ 使用 Gauss 积分有

$$\int_a^b w(x)dx = \sum_{i=0}^n A_i,$$

证毕。 \square

根据 Weierstrass 定理, 有界闭区间上的连续函数可以被多项式逼近, 因此对于任意 $f \in C[a, b]$, 给定任意 $\varepsilon > 0$, 都存在 $P \in \mathcal{P}$ 使得

$$|f(x) - P(x)| < \varepsilon, \quad \forall x \in [a, b].$$

使用这一事实我们可以证明使用 Gauss 积分计算 f 的广义积分的误差随着插值节点个数 n 的增大而收敛到零。

Theorem 1. Gauss 积分的收敛性 如果 $f \in C[a, b]$, 则对于任意 $\varepsilon > 0$, 存在 N 使得任意 $n > N$ 都有

$$\left| \int_a^b f(x)w(x)dx - \sum_{i=0}^n A_{ni} f(x_{ni}) \right| < \varepsilon, \quad (2.24)$$

因此 Gauss 积分的误差随着插值节点个数 n 的增大而收敛到零, 其中下标 ni 表示使用 A_{ni} 和节点 x_{ni} 与节点个数 n 有关。

Proof. 选取 $\varepsilon > 0$ 使得

$$2\varepsilon \int_a^b w(x)dx < \varepsilon,$$

根据 Weierstrass 定理, 存在 $P \in \mathcal{P}$ 使得

$$|f(x) - P(x)| < \varepsilon, \quad \forall x \in [a, b].$$

使用三角不等式可知

$$\begin{aligned}
\left| \int_a^b f(x)w(x)dx - \sum_{i=0}^n A_{ni}f(x_{ni}) \right| &\leq \left| \int_a^b f(x)w(x)dx - \int_a^b P(x)w(x)dx \right| + \left| \int_a^b P(x)w(x)dx - \sum_{i=0}^n A_{ni}f(x_{ni}) \right| \\
&\leq \int_a^b |f(x) - P(x)|w(x)dx + \left| \sum_{i=0}^n A_{ni}P(x_{ni}) - \sum_{i=0}^n A_{ni}f(x_{ni}) \right| \\
&\leq \epsilon \int_a^b w(x)dx + \sum_{i=0}^n A_{ni}|P(x_{ni}) - f(x_{ni})| \\
&\leq \epsilon \int_a^b w(x)dx + \sum_{i=0}^n A_{ni}\epsilon \\
&\leq 2\epsilon \int_a^b w(x)dx < \varepsilon,
\end{aligned}$$

其中我们令 N 为任意大于 $\deg P$ 的整数，证毕。 \square

更进一步地，我们可以给出 Gauss 积分的具体误差公式。

Theorem 2. $n+1$ 节点 Gauss 积分的误差公式 如果 $f \in C^{2n+2}[a, b]$ ，则存在 $\xi \in (a, b)$ 使得

$$\int_a^b f(x)w(x)dx - \sum_{i=0}^n A_i f(x_i) = \frac{f^{(2n+2)}(\xi)}{(2n+2)!} \int_a^b \prod_{i=0}^n (x - x_i)dx. \quad (2.25)$$

Proof. 令 P 为 f 在 Gauss 插值节点处的二重 Hermite 插值多项式，即

$$P(x_i) = f(x_i), \quad P'(x_i) = f'(x_i), \quad i = 0, 1, \dots, n,$$

于是 $\deg P = 2n+1$ ，插值误差为

$$f(x) - P(x) = \frac{f^{(2n+2)}(\xi_x)}{(2n+2)!} \prod_{i=0}^n (x - x_i)^2,$$

将上式关于 w 积分并使用 Gauss 积分即可得到

$$\int_a^b f(x)w(x)dx - \sum_{i=0}^n A_i f(x_i) = \frac{1}{(2n+2)!} \int_a^b f^{(2n+2)}(\xi_x) \prod_{i=0}^n (x - x_i)^2 dx,$$

使用积分中值定理可知上式右侧等于

$$\frac{f^{(2n+2)}(\xi)}{(2n+2)!} \int_a^b \prod_{i=0}^n (x - x_i)dx,$$

因此

$$\int_a^b f(x)w(x)dx - \sum_{i=0}^n A_i f(x_i) = \frac{f^{(2n+2)}(\xi)}{(2n+2)!} \int_a^b \prod_{i=0}^n (x - x_i)dx,$$

证毕。 \square

2.3 Romberg 积分

当使用复合梯形法则时，类似于数值微分中的 Richardson 外推法，我们可以通过递推的方式提高数值积分的精度，在这个过程中，我们希望可以充分利用以往的计算结果以减少计算量（用内存换速度），相应的方法称为 Romberg 积分。

令计算步长为 $h = (b - a)/n$ ，则记复合梯形法则为

$$T(n) = \frac{h}{2} \left[f(x_0) + 2 \sum_{i=1}^{n-1} f(x_i) + f(x_n) \right] = \frac{b-a}{2n} \left[f(a) + 2 \sum_{i=1}^{n-1} f(a + \frac{b-a}{n}i) + f(b) \right], \quad (2.26)$$

注意到当步长减半时，原本的节点仍然在被使用，因此无需重复计算这一部分极点处的值，更准确地说，我们有

$$\begin{aligned}
T(2n) &= \frac{b-a}{4n} \left[f(a) + 2 \sum_{i=1}^{2n-1} f(a + \frac{b-a}{2n}i) + f(b) \right] \\
&= \frac{1}{2}T(n) + \frac{b-a}{2n} \sum_{i=1}^{n-1} f(a + \frac{b-a}{2n}(2i-1)),
\end{aligned} \quad (2.27)$$

重复使用上式可得

$$T(2^n) = \frac{1}{2}T(2^{n-1}) + \frac{b-a}{2^n} \sum_{i=1}^{2^n-1} f\left(a + \frac{b-a}{2^n}(2i-1)\right), \quad (2.28)$$

于是使用这一递推关系可以较高效地计算出 $T(2^n)$ ，这一方法称为 Romberg 积分。

通常 Romberg 积分可以借助 Richardson 外推法提高精度，这一过程往往使用表格来计算。令表格的第一列为 $R(n, 0) = T(2^n)$ 。注意到梯形法则具有二阶精度且误差中不含有奇数次项，因此 Richardson 外推过程中的递推关系为

$$R(n, k) = \frac{4^k}{4^k - 1} R(n, k-1) - \frac{1}{4^k - 1} R(n-1, k-1), \quad (2.29)$$

其中 $n = 2^k, \dots, M$, $k = 1, 2, \dots, n$ 。计算表格为

| | | | | |
|-----------|-----------|-----------|----------|-----------|
| $R(0, 0)$ | | | | |
| $R(1, 0)$ | $R(1, 1)$ | | | |
| $R(2, 0)$ | $R(2, 1)$ | $R(2, 2)$ | | |
| \vdots | \vdots | \vdots | \ddots | |
| $R(M, 0)$ | $R(M, 1)$ | $R(M, 2)$ | \cdots | $R(M, M)$ |
